

Атлас локальных экономик

Методологический отчёт

z1nex · октябрь 2026 · атлас: z1nex.online/atlas · код: github.com/z1nex-1/sber_index

1 Коротко

Я построил динамическую атрибутированную сеть из 2 016 муниципалитетов за 22 месячных среза 2023–2024 годов и разделил её на семь типов локальных экономик. Узел — муниципалитет, атрибуты — структура трат по категориям относительно страны, уровень трат на жителя и ритм трат в году, рёбра — сходство профилей, взвешенное близостью по дорогам. Итоговая модель — спектральная кластеризация на смеси ядра признаков и нормированной смежности, $k = 7$.

Её выбрали из 342 разбиений: восемь методов, семь правил рёбер, k от 4 до 12. Шесть индексов качества сведены в одно место правилами Кемени, Борда и Коупленда. Итоговая модель первая по правилу Кемени при 8 значениях k из 9. На подвыборках из 80% муниципалитетов она воспроизводится с ARI 0,92, при смене seed — 1,00.

Типы совпадают с тем, что в модель не входило: с районами Крайнего Севера (V Крамера 0,78), с численностью населения (η^2 0,42) и с индексом доступности рынков (η^2 0,56). С регионами они совпадают умеренно, NMI 0,32. Помесячная скрытая марковская модель нашла 37 муниципалитетов, которые за два года устойчиво сменили тип. При перемешанных месяцах таких получается $15,3 \pm 7,5$.

Разделы отчёта идут в порядке критериев оценки.

Критерий	Что показано	Где
Простота и воспроизводимость методологии	Схема расчёта, одна команда, конфиги, тесты	\$2, \$9
Сетевая и атрибутивная структура	Обоснование признаков, 7 правил рёбер, их свойства и чувствительность	\$3, \$4
Сравнение методов	8 методов в трёх семействах, плюсы, минусы, условия применения	\$5
Использование ICVI	Все шесть индексов, перекрёстная оценка, сведение мест, устойчивость	\$6
Интерпретация и обоснованность	Семь типов, формальные понятия, внешняя проверка, динамика, сценарии применения, ограничения	\$7, \$8, \$10, \$11
Инновационная визуализация	Интерактивный атлас из семи листов	\$12

2 Данные и схема расчёта

Используются все наборы СберИндекса к конкурсу. Первый — оценки средних безналичных трат жителя по пяти категориям и в целом за январь 2023 — декабрь 2024. Остальные — индекс доступности рынков, расстояния между центрами МО по автодорогам и справочник МО с границами. Полные 24 месяца есть у 2 016 МО из 2190, их и берём. Внешние данные нужны только для проверки и в модель не входят. Это численность населения МО на 1 января 2024 года, список районов Крайнего Севера и список моногородов из бюллетеня Росстата. Население

сопоставлено с МО по ОКТМО, а при смене кода — по названию внутри региона; найдено 2013 МО из 2016.




Таблица 1. Схема расчёта. Каждому блоку соответствует модуль в `src/atlas`, все параметры — в `configs/default.yaml`.

Весь расчёт — это команды `make data run site` или `atlas fetch, atlas run, atlas export`, на ноутбуке он занимает около пяти минут. Seed фиксирован, данные скачиваются скриптом и сверяются по контрольным суммам.

3 Атрибуты узлов

3.1 Структура трат

Доли категорий в тратах МО — композиционные данные: в сумме они дают единицу. Если одна доля растёт, остальные падают даже без собственных изменений. Евклидово расстояние по сырым долям это искажает, поэтому доли переводятся в центрированные логарифмы отношений (CLR, Эйчисон):

$$\text{clr}(x)_j = \ln x_j - \frac{1}{D} \sum_{i=1}^D \ln x_i,$$

где $D = 6$: пять категорий и «прочее», то есть разница между общими тратами и суммой категорий. Доли ниже 0,2% поднимаются до этого порога, иначе логарифм взрывается на мелких районах.

Затем CLR-признаки берутся относительно медианы страны в том же месяце. За два года доля маркетплейсов по стране выросла так, что медианный CLR маркетплейсов сдвинулся на 0,7 стандартного отклонения. Без этого шага почти каждый МО к концу 2024 года «переходил» бы в тип с высокой долей маркетплейсов. Тип здесь понимается как положение МО относительно страны, а не как общий тренд.

3.2 Уровень и ритм трат

Уровень — логарифм общих трат на жителя минус медиана по стране в том же месяце. Так уходят общая сезонность и инфляция. Ритм — три признака, постоянных для МО:

- сезонная амплитуда — стандартное отклонение среднего годового профиля отклонений r_t от страны;
- летний пик — средний профиль за июнь–август минус среднее за год;
- волатильность — стандартное отклонение остатка после вычитания профиля и линейного тренда.

Все ряды сглажены скользящей суммой за 3 месяца, чтобы мелкие районы не шумели. Блоки признаков стандартизованы и взвешены: у структуры и уровня вес 1, у ритма 0,6. Каждый блок делится на корень из своей размерности, чтобы шесть CLR-признаков не перевешивали один уровень.

3.3 Что даёт каждый блок

Индекс доступности рынков в модель не включён. Он описывает положение МО, а не траты жителей, и позволяет независимо проверить типы. Географию в модель вносит сеть через

дороги. Абляция показывает, как меняется итоговое разбиение при другом наборе признаков (сеть при этом каждый раз строится заново):

Набор признаков	Признаков	ARI с итогом	SW	MQ на корреляционной сети
структура	7	0,32	0,15	0,37
структура + уровень	7	0,83	0,21	0,46
структура + уровень + ритм	10	1,00	0,18	0,46
+ доступность рынков	11	0,83	0,21	0,47
без сглаживания	10	0,98	0,18	0,46

Таблица 2. Абляция признаков для итогового метода, $k = 7$.

Без уровня трат получается почти другая типология: ARI с итогом 0,32. Ритм меняет её умеренно (ARI 0,83), зато выделяет северные и удалённые территории с сильными летними колебаниями. Доступность рынков улучшила бы S_Dbw, но лишила бы нас независимой проверки. Без сглаживания разбиение почти то же (ARI 0,98), то есть окно в три месяца не подгоняет результат.

4 Правила рёбер

Все сети строятся как симметризованные графы k ближайших соседей ($k_{nn} = 15$) по матрице сходства S . Вес ребра — сходство, отрицательные значения обнуляются. Для динамики сеть строится по каждому месяцу, для итоговой типологии — по профилю за весь период.

- Сходство профилей:** $S_{ij} = \cos(x_i, x_j)$ по вектору признаков. Связывает похожие экономики на любом расстоянии.
- Синхронность колебаний:** корреляция помесечных отклонений логарифма трат от медианы страны по всем категориям в окне 12 месяцев. Связывает территории, которые одинаково реагируют на шоки.
- Опережение с лагом:** максимум той же корреляции по сдвигам $|\ell| \leq 2$ месяца; направление опережения сохраняется.
- DTW:** расстояние динамической трансформации времени между рядами общих трат относительно страны, окно Сакоэ — Тибы ± 2 месяца, $S = \exp(-d / \text{med}(d))$. Полный DTW для двух миллионов пар не нужен: для каждого МО считаются 60 ближайших по корреляции кандидатов.
- Дороги:** $S_{ij} = \exp(-\tau_{ij}/300 \text{ км})$ по расстоянию между центрами МО по автодорогам.
- Гибрид:** $S = 0.7 \cdot (\cos + 1)/2 + 0.3 \cdot \exp(-\tau/300)$ — экономика, взвешенная географией.
- Мультиплекс:** среднее нормированных $D^{-1/2}AD^{-1/2}$ слоёв 1, 2 и 5.

Правило	Рёбер	Степень	Кластеризация	Компонент	Внутри региона	Медиана, км
профили	21 232	21,1	0,35	1	23%	724
корреляция	25 176	25,0	0,27	1	27%	652
лаг	25 367	25,2	0,26	1	26%	731
DTW	23 653	23,5	0,26	1	18%	1 071
дороги	18 675	18,5	0,62	12	72%	106
гибрид	20 049	19,9	0,44	1	57%	154
мультиплекс	56 880	56,4	0,24	1	33%	451

Таблица 3. Свойства сетей по профилю за весь период.

Правила дают принципиально разные сети. Сети по динамике (корреляция, лаг, DTW) почти не знают географии: медианное ребро — около тысячи километров, внутри региона меньше четверти связей. Их коэффициент кластеризации самый низкий, степени самые неравные. Дорожная сеть наоборот: 72% связей внутри региона, 12 компонент (острова и изолированные районы Севера), кластеризация 0,62 — она просто повторяет административную карту. Гибрид

сохраняет короткие связи (медиана 154 км) и одну компоненту, но соединяет только экономически похожих соседей.




Рис. 1. Чувствительность к числу соседей k_{nn} . Слева — модулярность итоговых типов в сети, справа — доля связей внутри региона.

Итоговым выбран гибридный, и на то три довода. Сеть, по которой делится страна, должна связывать и похожие, и достижимые друг для друга территории: для практических задач вроде сравнения политики соседних районов или логистики сервисов нужно и то и другое. Кроме того, на гибриде итоговое разбиение устойчиво при любом k_{nn} от 5 до 30 (рис. выше). Наконец, на гибриде выигрывают почти все атрибутированные методы (§6). Сети по динамике используются для независимой оценки качества: они построены из других данных, чем признаки и дороги.

5 Методы кластеризации

Сравниваются восемь методов из трёх семейств. Все получают одинаковые признаки (профиль за весь период), а методы, использующие сеть, — каждую из семи сетей.

Метод	Что делает	Сильные стороны	Слабые стороны, когда не применять
k-средних	Минимизирует внутрикластерный разброс	Быстрый, понятный центр типа	Сферические кластеры равного размера; на подвыборках ARI 0,84 при $k = 7$ против 0,92 у итогового метода
Гауссова смесь	Смесь нормальных распределений с полными ковариациями, EM	Эллиптические кластеры, мягкие вероятности	Много параметров; сильно зависит от старта: ARI между seed от 0,56 до 0,84
Уорд	Агломеративное слияние с минимальным ростом разброса	Детерминирован, даёт дерево типов	Жадные слияния необратимы; на подвыборках ARI от 0,47 до 0,60
Спектральная по сети	k собственных векторов лапласиана, затем QR-назначение	Находит связанные сообщества любой формы	Не видит признаков; на дорожной сети повторяет регионы
Leiden	Максимизирует модулярность RB, разрешение подбирается под k	Гарантирует связанные сообщества, быстр	k задаётся косвенно; мелкие сообщества приходится присоединять
Спектральная: признаки + сеть	Спектральная на $W = \gamma K + (1 - \gamma)\hat{A}$: K — гауссово ядро с локальным масштабом, $\hat{A}$ — нормированная смежность, $\gamma = 0.5$	Учитывает оба источника в одной матрице, устойчив	Плотная матрица $n \times n$: до 20 тыс. узлов; γ — гиперпараметр
SEFNAC	Последовательно извлекает сообщества, максимизируя вклад в восстановление признаков и связей (Shalileh, Mirkin)	Сам решает, где остановиться; вклад каждого сообщества интерпретируем	Жадный рост; при $k \geq 8$ даёт сообщества меньше 1% МО
DMoN	GCN-кодировщик с функцией потерь «спектральная модулярность + штраф за схлопывание» (Tsitsulin и др.)	Нелинейно смешивает признаки и сеть, масштабируется	Нужен PyTorch, результат зависит от seed и числа эпох; уступает по индексам признаков

Таблица 4. Методы, их плюсы, минусы и условия применения.

Две детали пришлось доработать, иначе сравнение было бы нечестным. В атрибутированной спектральной кластеризации ядро признаков с общим масштабом σ давало один кластер из тысячи с лишним МО и несколько кластеров из выбросов. У типичных районов плотное облако, и спектральный метод отделял только края. Ядро с локальным масштабом (Zelnik-Manor, Perona) $K_{ij} = \exp(-d_{ij}^2/(\sigma_i\sigma_j))$, где σ_i — расстояние до 15-го соседа, эту проблему убирает. Вторая деталь касается Leiden: он не принимает k на вход. Разрешение подбирается бисекцией так, чтобы крупных (не меньше 0,5% узлов) сообществ было k , мелкие присоединяются к соседнему по весу связей.

Разбиение допускается к сравнению, если в нём нет кластера меньше 1% МО, то есть 20 территорий. Тип из пяти районов бесполезен для интерпретации, а индексы такие разбиения часто поощряют.

6 Индексы качества

6.1 Шесть индексов

SW (силуэт), CH (Калински — Харабаш) и S_Dbw (Halkidi, Vazirgiannis) считаются по признакам. Графовые индексы считаются по взвешенной сети. Пусть $w_{in}(c)$ — суммарный вес рёбер внутри кластера c , $w_{cut}(c)$ — вес рёбер из c наружу, $w(c, c')$ — вес рёбер между c и c' . Тогда

$$AVI = \frac{1}{k} \sum_c \frac{w_{in}(c)}{w_{in}(c) + w_{cut}(c)}, \quad AVU = \frac{2}{k(k-1)} \sum_{c < c'} \frac{w(c, c')}{w_{in}(c) + w_{in}(c') + w(c, c')},$$

$$MQ = \frac{1}{2m} \sum_{ij} \left(A_{ij} - \frac{d_i d_j}{2m} \right) \delta(c_i, c_j).$$

AVI — средняя изолированность кластеров, AVU — средняя связанность пар кластеров (лучше меньше); оба по мотивам Biswas, Biswas (2017). MQ — модулярность Ньюмана. Все индексы проверены тестами на данных с известной структурой (tests/test_icvi.py): несвязные клики дают $AVI = 1$ и $AVU = 0$, случайная перестановка меток ухудшает SW, CH и S_Dbw.

6.2 Графовые индексы на независимых сетях

Графовые индексы зависят от сети, на которой их считать. Метод, который оптимизировал модулярность гибридной сети, на ней же и выигрывает. Рисунок ниже показывает это на лучших разбиениях каждого метода при $k = 7$: на собственной сети (рамка) модулярность выше, чем на остальных.

k-средних (без сети)	0,57	0,35	0,33	0,26	0,28	0,48	0,37
Гауссова смесь (без сети)	0,51	0,38	0,36	0,29	0,30	0,46	0,37
Уорд (без сети)	0,55	0,35	0,33	0,25	0,28	0,46	0,37
Спектральная по сети (профили)	0,64	0,35	0,33	0,24	0,30	0,53	0,42
Leiden (гибрид)	0,46	0,48	0,44	0,32	0,68	0,78	0,52
Спектральная: признаки + сеть (гибрид)	0,51	0,46	0,44	0,33	0,37	0,56	0,41
SEFNAC (профили)	0,50	0,36	0,34	0,26	0,31	0,47	0,37
DMoN (гибрид)	0,53	0,43	0,40	0,31	0,53	0,71	0,49
	профили	корреляция	лаг	DTW	дороги	гибрид	мультиплекс

Рис. 2. Модулярность лучшего разбиения каждого метода при $k = 7$ на каждой из семи сетей. Рамка — сеть, на которой метод обучался.

Поэтому источники сетей разделены на три группы: признаки (профили), ряды (корреляция, лаг, DTW) и дороги. Графовые индексы разбиения усредняются только по сетям, у которых нет общих источников с данными метода. Признаковые методы оцениваются на рядах и дорогах, атрибутированный метод на гибриде — на рядах. У разбиений на мультиплексе независимой сети нет совсем, поэтому они остаются только в перекрёстной таблице. Это сужает сравнение, но иначе итог определялся бы тем, кто на какой сети обучался.

6.3 Сведение мест

Индексы согласуются плохо. Коэффициент конкордации Кендалла W по шести индексам — от 0,33 до 0,50 в зависимости от k . Выбирать модель по одному индексу значит выбирать индекс. Места сведены тремя правилами голосования, где каждый индекс — избиратель:

- **Борда:** сумма рангов по индексам;
- **Коупленд:** число побед в попарных сравнениях по большинству индексов минус число поражений;
- **Кемени:** порядок, минимально расходящийся с попарным большинством. Ищется перестановками соседних пар от порядка Борда до тех пор, пока ни одна соседняя пара не противоречит большинству. Это локальный оптимум расстояния Кемени.

Сравнивать разные k по SW и CH нельзя, оба смещены к малым k . Поэтому места считаются внутри каждого k , а сам k выбирается отдельно, по устойчивости.

k-средних	2	4	4	4	2	4	2	2	2
Гауссова смесь	8	3	3	6	8	8	8	10	4
Уорд	1	5	5	7	4	3	3	5	3
Спектральная по сети	9	15	8	8	6	11	7	6	7
Leiden	13	10	9	9	10	6	6	4	6
Спектральная: признаки + сеть	3	1	1	1	1	1	1	1	1
SEFNAC	5	12	10	15	—	—	—	—	—
DMoN	11	9	16	3	3	2	5	3	8
	k=4	k=5	k=6	k=7	k=8	k=9	k=10	k=11	k=12

Рис. 3. Место лучшего варианта метода по правилу Кемени среди допустимых разбиений с тем же k . Прочерк — нет допустимого разбиения.

Спектральная кластеризация на признаках и гибридной сети первая при 8 значениях k из 9 по Кемени и при большинстве k по Борда и Коупленду. При $k = 4$ выигрывает Уорд, но это самый неустойчивый метод. k -средних и Уорд сильны в индексах признаков (SW, CH, S_Dbw), графовые методы — в AVI и MQ. Атрибутированный метод не лучший ни по одному индексу, зато нигде не проваливается. Именно такой компромисс правила голосования и должны находить.

6.4 Устойчивость и выбор числа типов

Для итогового метода при каждом k и для тройки лидеров по каждому k разбиение повторялось на 20 случайных подвыборках из 80% МО и при пяти других seed. Сравнение с исходным разбиением на общих МО — по скорректированному индексу Рэнда.




Рис. 4. Устойчивость на подвыборках. Линия — итоговый метод, заливка — от 10-го перцентиля до среднего; точки — другие кандидаты.

До $k = 7$ итоговый метод держится с ARI выше 0,92. При $k = 8$ ARI падает до 0,74: половина страны — ядро сельских и малгородских районов — начинает делиться, но на разных подвыборках по-разному. Различия внутри ядра плавные, это континуум, а не несколько типов. Поэтому $k = 7$ — самое большое число типов, которое воспроизводится. У k -средних с тем же k ARI на подвыборках 0,84, при смене seed — 0,98.

7 Динамика

7.1 Помесячный тип

Отнести каждый месяц к ближайшему центру типа — плохая идея. Разовый выброс месяца меняет тип, и за два года тип хотя бы раз меняли бы 15% МО. Помесячный тип строится как путь скрытой марковской модели:

$$\log p(x_{it} | c) = -\frac{\|x_{it} - m_c\|^2}{\tau} + \lambda F_{itc},$$

где m_c — центр типа c по итоговому разбиению, τ — медиана квадратов расстояний до своего центра, F_{itc} — доля веса связей МО i в месячной гибридной сети, приходящаяся на соседей типа c . Вес $\lambda = 2,5$ подобран так, чтобы на профиле за весь период модель лучше всего воспроизводила итоговые типы: совпадение 96%. Без сетевого слагаемого совпадение 86%. Остаться в типе можно с вероятностью $1 - p$, сменить его — с вероятностью $p/(k - 1)$, $p = 0.03$. Путь декодируется алгоритмом Витерби.

Смена считается устойчивой, если новый тип держится не меньше 6 месяцев до конца периода. Таких МО 37. Проверка на шум — блочная перестановка: месяцы перемешиваются блоками по три, чтобы сохранить автокорреляцию от сглаживания, но разрушить реальный порядок. В 50 перестановках получается $15,3 \pm 7,5$ устойчивых смен, и ни одна не дала 37 и больше.




Рис. 5. Число устойчивых смен типа при перемешанных месяцах и наблюдаемое число.

p	Устойчивых смен	В нуле	Хотя бы одна смена
0,01	29	$10,3 \pm 6,8$	5%
0,03	37	$15,8 \pm 8,1$	6%
0,10	50	$25,9 \pm 10,7$	6%

Таблица 5. Чувствительность к вероятности смены типа за месяц.

Вывод от p не зависит: реальных смен примерно вдвое больше, чем даёт шум. Типология за два года почти неподвижна. Большинство смен — переходы между «промышленными и региональными городами» и «сельской и малгородской Россией», то есть по краю сплошного ядра. Есть и понятные случаи. Верхоянский и Томпонский районы Якутии перешли из «удалённых» в «северные ресурсные»; Липецк и Кольцово ушли из «городов» к столичным агломерациям.

Ещё у 71 МО помесечная модель весь период предпочитает не их итоговый тип: признаки ближе к одному типу, а соседи по сети держат в другом. Пример — Петропавловск-Камчатский: по тратам он ближе к центру Москвы, по сети — к Северу. В атласе такие МО помечены как пограничные, и на карте они показаны в своём итоговом типе.

7.2 Мультислойный Leiden и события

Для сравнения — чисто сетевой взгляд на динамику. Мультислойный Leiden (Mucha и др.) решает задачу для всех 22 месячных сетей сразу: узел связан сам с собой в соседних месяцах весом ω . Жизнь сообществ отслеживается по Greene и др.: сообщество месяца $t + 1$ продолжает сообщество месяца t , если их коэффициент Жаккара не ниже 0,3. Остальные случаи — распад, слияние, появление, исчезновение.

ω	Сообществ	NMI с типами	Продолжение	Распад	Слияние	Появл./исчезн.
0,00	6–9	0,44	140	7	5	13
0,05	7–9	0,44	149	3	4	13
0,20	6–8	0,44	149	2	2	9
1,00	7–7	0,45	147	0	0	0

Таблица 6. Мультислойный Leiden на месячных гибридных сетях, разрешение 0,3.

При $\omega = 0$ срезы независимы, и сообщества то распадаются, то сливаются: это шум разбиения, а не экономики. При $\omega = 1$ событий нет совсем. Результат задаётся параметром, а не данными, поэтому для атласа выбрана скрытая марковская модель: у неё есть проверка на нулевой модели. Сообщества Leiden совпадают с нашими типами слабо (NMI около 0,45). Чисто сетевые сообщества гибрида в основном повторяют крупные географические зоны.

8 Семь типов




Рис. 6. Типы за весь период. Серой штриховкой — МО без полных рядов.

Центр Москвы	-36%	+28%	-20%	+234%	+26%	+36%	+121%
Московская агломерация	-24%	+8%	-1%	+161%	+29%	+17%	+78%
Петербургская агломерация	-27%	+20%	-17%	+204%	+28%	+24%	+74%
Север	-9%	-19%	-12%	+58%	-20%	+19%	+61%
Города	-7%	-1%	-7%	+55%	+6%	+7%	+17%
Удалённые районы	-1%	-19%	-29%	+9%	+27%	+8%	+5%
Малые города и село	+6%	-0%	+12%	-36%	-8%	-12%	-15%

Продовольствие	Здоровье	Маркетплейсы	Общественное питание	Транспорт	Прочее	траты на жителя
----------------	----------	--------------	----------------------	-----------	--------	-----------------

Рис. 7. Медианное отклонение долей категорий и трат на жителя от медианы страны по типам.

- 1. Центр и запад Москвы (55 МО).** Центральный округ и районы запада, юго-запада и севера. Траты больше чем вдвое выше медианы, общепит занимает втрое большую долю, продукты — на треть меньшую.
- 2. Московская агломерация (150).** Восток и юго-восток Москвы, города Подмосковья и областные центры вокруг: Калуга, Тула, Рязань, Тверь, Смоленск. Траты на 79% выше медианы.
- 3. Петербург и пригороды (110).** Уровень как в Подмосковье, но меньше маркетплейсов и больше трат на здоровье.
- 4. Северные ресурсные территории (130),** девять из десяти — на Крайнем Севере. Траты на 58% выше медианы, летом растут сильнее, чем в среднем по стране.

5. **Промышленные и региональные города** (435). Структура близка к средней, уровень на 15–20% выше.
6. **Удалённые районы с сезонными тратами** (111): сельские районы Якутии, Забайкалья, Тывы, Республики Алтай. Самая сильная сезонность, высокая доля транспорта.
7. **Сельская и малогородская Россия** (1025). Траты на 15% ниже медианы, выше доли продуктов и маркетплейсов, общепит на треть ниже.

Столица делится на три типа. Центр и запад Москвы образуют клин от центра на юго-запад, восток и юго-восток города вместе с Подмосковьем составляют отдельный тип, а Петербург — свой. Внутри Москвы разница в тратах между этими типами больше, чем между Подмосковьем и Калугой.




Рис. 8. Москва: центр и запад (коричневый) и остальная агломерация.

8.1 Формальные понятия

Кластер описан, только если понятно, какие признаки его отличают. Для этого построен формальный контекст «МО × бинарный признак». Каждый числовой признак (доли, траты, ритм) шкалирован интерпорядково: не ниже 90, 75 и 25-го перцентилей и не выше 75, 25 и 10-го, всего 60 признаков. Для каждого типа перебираются наборы из одного–трёх признаков B . Выбирается тот, чей объём B' лучше всего совпадает с типом по F1 при точности не ниже 50% и объёме не меньше 10 МО. Замыкание (B' , B'') — формальное понятие. Для него указана Δ -мера устойчивости (Buzmakov, Kuznetsov, Napoli): на сколько МО сократится объём, если добавить любой новый признак.

Тип	Порождающие признаки понятия	Объём	Точность	Охват	Δ
1	Здоровье $\geq q90$; траты на жителя $\geq q90$; летний пик $\geq q25$	79	57%	82%	1
2	Маркетплейсы $\geq q25$; траты на жителя $\geq q75$; летний пик $\leq q75$	218	66%	96%	3
3	Маркетплейсы $\leq q25$; Общественное питание $\geq q90$; Прочее $\geq q75$	121	55%	61%	1
4	Здоровье $\leq q75$; траты на жителя $\geq q75$; летний пик $\geq q75$	128	81%	80%	1
5	Маркетплейсы $\leq q25$; траты на жителя $\geq q25$; траты на жителя $\leq q75$	192	56%	25%	6
6	Транспорт $\geq q75$; сезонность $\geq q25$; летний пик $\geq q75$	79	65%	46%	4
7	Общественное питание $\leq q75$; Прочее $\leq q75$; траты на жителя $\leq q75$	1327	76%	98%	33

Таблица 7. Описание типов формальными понятиями. Точность — доля МО понятия, принадлежащих типу; охват — доля типа внутри понятия.

Три признака описывают северный тип (F1 0,81), ядро (0,85) и московскую агломерацию (0,78). Хуже всего описывается тип «промышленные и региональные города» (охват 25%). Он лежит в середине всех распределений, а процентильные пороги выделяют края. Это ограничение не только описания, но и самого типа: «города» — переходная зона между столичными агломерациями и ядром. У понятий с малым Δ объём держится на нескольких МО у порога, поэтому они описывают тип, но не являются его определением.

8.2 Внешняя проверка

Переменная	Мера	Значение	Тест
численность населения, log	η^2	0,42	Краскел — Уоллис, $p < 0,001$
доля городского населения	η^2	0,40	Краскел — Уоллис, $p < 0,001$
индекс доступности рынков, log	η^2	0,56	Краскел — Уоллис, $p < 0,001$
Крайний Север	V Крамера	0,78	χ^2 , $p < 0,001$
моногород	V Крамера	0,26	χ^2 , $p < 0,001$
вид МО	V Крамера	0,57	χ^2 , $p < 0,001$
регион	V Крамера	0,73	χ^2 , $p < 0,001$
регион	NMI	0,32	

Таблица 8. Связь типов с переменными, не входившими в модель.

Типы сильно связаны с Крайним Севером, видом МО (городской округ, район, внутригородская территория) и численностью населения. Но это не пересказ административного деления. С регионами связь умеренная (NMI 0,32), и в 64 регионах из 73 встречается больше одного типа. Пространственная автокорреляция типов высокая: 64% связей дорожной сети соединяют МО одного типа, а при случайной перестановке типов — 32% ($z = 106$). Типы образуют связные зоны, хотя сама кластеризация видит дороги только через 30% веса гибридной сети.

9 Воспроизводимость

make setup data run site test. Все параметры — в `configs/default.yaml`, названия и описания типов — в `configs/types.yaml`. Итоговая модель зафиксирована в разделе `final` конфига. Таблицы, на которых основан выбор, пересчитываются командой `atlas run` и лежат в `outputs/`. Числа в этом отчёте читаются из них при сборке: `typst compile report/report.typ`. Тесты проверяют индексы, правила голосования, скрытую марковскую модель и восстановление подсаженного разбиения атрибутированными методами.

10 Как это использовать

- **Двойники для сравнения политики.** У каждого МО есть шесть самых похожих по структуре трат территорий из других регионов. Пример — Воркута: её двойники — северные ресурсные города с косинусным сходством 0,96–0,98. Эффект местной меры удобно сравнивать с двойниками, а не с соседями, у которых другая экономика.
- **Адресная поддержка.** «Удалённые районы с сезонными тратами» — 111 сельских районов с самой сильной сезонностью и высокой долей транспорта. Для них важнее меры, выравнивающие сезонные провалы, чем меры для «ядра».
- **Размещение сервисов.** Тип задаёт структуру спроса: в «городах» доля общепита в полтора раза выше медианы при среднем уровне трат, в «ядре» — на треть ниже. Это грубый, но дешёвый фильтр для выбора площадок.
- **Раннее обнаружение дрейфа.** Помесячная модель отличает устойчивую смену типа от разового отклонения и проверяет её на нулевой модели. Её можно пересчитывать ежемесячно на новых данных.

11 Ограничения

Оценки трат — модельные и только безналичные, а доля наличных в регионах разная. Особенно это касается Северного Кавказа, где часть МО не прошла порог качества. 174 МО с неполными рядами в модель не вошли. Двух лет мало, чтобы отделить тренд от колебаний, поэтому о дрейфе типов здесь говорится осторожно. Внутригородские территории Москвы и Петербурга — отдельные МО, хотя жители тратят деньги по всему городу; поэтому траты центральных районов отчасти отражают место работы, а не жительства. Формулы AVI и AVU записаны по определениям изолированности и связанности кластеров из Biswas, Biswas (2017) и могут отличаться деталями нормировки от реализации организаторов.

12 Интерактивный атлас

Атлас — статический сайт на D3 без сервера, семь листов:

1. **Карта типов** с ежемесячным ползунком и проигрыванием, штриховкой как вторым кодом цвета, поиском и приближением к агломерациям. Карточка МО содержит розу трат относительно страны, траекторию типа по месяцам, траты по месяцам, двойников и соседей по сети. Два МО можно сравнить; ссылка на выбор сохраняется в адресе.
2. **Пространство сходства**: те же МО, плавно перетекающие из географических координат в t-SNE по профилю, с выделением области и сводкой по ней.
3. **Портреты типов** с формальными понятиями.
4. **Переходы**: потоки между кварталами, список устойчиво сменивших тип и сравнение с нулевой моделью.
5. **Сеть близости**: семь правил рёбер на карте с таблицей свойств и подсветкой связей узла.
6. **Сравнение методов**: матрица мест по трём правилам голосования, положение выбранного разбиения среди всех конкурентов по каждому индексу, согласие индексов.
7. **Как это устроено** — краткая схема расчёта с числами из результатов.

13 Литература

Aitchison J. The Statistical Analysis of Compositional Data. Chapman and Hall, 1986.

Biswas A., Biswas B. Defining quality metrics for graph clustering evaluation

Buzmakov A., Kuznetsov S. O., Napoli A. Scalable estimates of concept stability

Ganter B., Wille R. Formal Concept Analysis: Mathematical Foundations. Springer, 1999.

Greene D., Doyle D., Cunningham P. Tracking the evolution of communities in dynamic social networks

Halkidi M., Vazirgiannis M. Clustering validity assessment: finding the optimal partitioning of a data set

Kemeny J. Mathematics without numbers

Mucha P. J., Richardson T., Macon K., Porter M. A., Onnela J.-P. Community structure in time-dependent, multiscale, and multiplex networks

Shalileh S., Mirkin B. A one-by-one method for community detection in attributed networks

Traag V. A., Waltman L., van Eck N. J. From Louvain to Leiden: guaranteeing well-connected communities

Tsitsulin A., Palowitch J., Perozzi B., Müller E. Graph clustering with graph neural networks

Zelnik-Manor L., Perona P. Self-tuning spectral clustering

Алескеров Ф. Т., Хабина Э. Л., Шварц Д. А. Бинарные отношения, графы и коллективные решения. М.: Физматлит, 2012.

Данные: Лаборатория СберИндекс. Потребительские расходы, индекс доступности рынков, связи между муниципальными образованиями, справочник МО (CC BY-SA 4.0). Росстат. Численность населения Российской Федерации по муниципальным образованиям на 1 января 2024 года.